Web Scraping Tabanlı Kentsel Haber İzleme ve Harita Üzerinde Görselleştirme Sistemi

Abdullah Amin
Bilgisayar Mühendisliği Bölümü
Kocaeli Üniversitesi
Kocaeli, Türkiye
210201142@kocaeli.edu.tr

***Özet*—Günümüzde kentsel yaşamı etkileyen anlık olayların (trafik kazaları, yangınlar, güvenlik ihlalleri vb.) takibi, bilginin farklı yerel haber kaynaklarına dağılmış olması nedeniyle zorlaşmaktadır. Bu projenin amacı, Kocaeli iline ait güncel yerel haberlerin web scraping algoritmaları ile otomatik olarak toplanması, doğal dil işleme (NLP) teknikleriyle analiz edilerek sınıflandırılması ve interaktif bir harita üzerinde görselleştirilmesini sağlayan dinamik bir web tabanlı sistem geliştirmektir. Sistem, belirlenen 5 farklı yerel haber platformundan son 3 günlük verileri eşzamanlı ve asenkron (async) olarak çekmektedir. Bot korumalarını (Cloudflare WAF) aşabilen otonom sistemlerle elde edilen ham metinler, veri temizleme aşamalarından geçtikten sonra Derin Öğrenme tabanlı metin benzerliği (TF-IDF ve Cosine Similarity) algoritmalarıyla mükerrer kayıt kontrolüne (duplicate detection) tabi tutulmaktadır. Özgün haberler, mDeBERTa Zero-Shot yapay zeka modeli ve anahtar kelime eşleştirmeleri kullanılarak beş temel kategoriye (Trafik, Yangın, Hırsızlık, Elektrik Kesintisi, Kültürel Etkinlik) ayrıştırılmakta ve konum çıkarımı yapılmaktadır. Çıkarılan adres bilgileri, OpenCage Geocoding API ile enlem ve boylam koordinatlarına çevrilerek NoSQL tabanlı MongoDB veritabanında önbelleklenmektedir (caching). Geliştirilen React tabanlı dinamik kullanıcı arayüzü sayesinde, kullanıcılar olayları Google Maps üzerinde kategori, ilçe ve tarih filtreleriyle anlık olarak harita üzerinde takip edebilmektedir.**

***Anahtar Kelimeler*—Web Scraping, Doğal Dil İşleme, Coğrafi Bilgi Sistemleri, Veri Görselleştirme, MongoDB**

I. Giriş

Metropolleşen şehirlerde günlük hayatın akışını doğrudan etkileyen olayların (trafik kazaları, hava/yol durumu uyarıları, yangınlar ve altyapı arızaları) hızlı ve doğru bir şekilde kamuoyuna ulaştırılması büyük önem taşımaktadır. Ancak günümüzde bu tür kritik yerel gelişmeler, çok sayıda farklı haber sitesi, belediye portalı veya dijital medya organlarına dağınık bir şekilde düşmektedir. Kocaeli gibi yoğun sanayi ve nüfus hareketliliğine sahip bir şehirde, vatandaşların veya yetkililerin güncel durumlara bütüncül ve lokasyon tabanlı (geospatial) bir bakış açısıyla, anında erişebilmesi mevcut geleneksel haber okuma alışkanlıklarıyla oldukça zordur.

Bu problemin çözümü motivasyonuyla yola çıkılan bu projede, Kocaeli ilindeki haber kaynaklarından veri toplayan, metin madenciliği alanındaki problemleri çözen ve veriyi son kullanıcıya uzamsal (spatial) olarak sunan uçtan uca (end-to-end) bir platform tasarlanmıştır. Proje kapsamında Kocaeli sınırları içinde yayın yapan beş farklı yerel haber sitesi hedeflenmiş olup, toplanan ham veriler gelişmiş Doğal Dil İşleme (NLP) süreçlerinden geçirilmektedir.

Sistemin temel hedefleri şunlardır:

Dağınık haber kaynaklarından asenkron web scraping yöntemleriyle otomatize veri madenciliği yapmak, Geliştirilen benzerlik algoritmaları ile haber kirliliğini (farklı kurumlardan çıkan aynı içerikli haberleri) filtreleyerek temiz ve tekilleştirilmiş veri setleri oluşturmak, Olay türlerini (Trafik Kazası, Yangın, Hırsızlık, Elektrik Kesintisi, Kültürel Etkinlik) akıllı sınıflandırma yöntemleriyle ayırt etmek, Yapısal olmayan (unstructured) metinlerden konum bilgisini ayrıştırıp koordinatlara (Geocoding) dönüştürmek, Modern, tepkisel (reactive) ve kullanıcı dostu bir arayüz ile bu verileri dijital harita üzerinde dinamik olarak görselleştirmektir.

II. Kullanılan Yöntemler ve Teknolojiler

A. Web Scraping ve Veri Toplama

Sistemin veri tedarik katmanı, Kocaeli yerel basınının önde gelen beş farklı dijital haber platformunu (Özgür Kocaeli, Çağdaş Kocaeli, Ses Kocaeli, Yeni Kocaeli ve Bizim Yaka) eşzamanlı olarak tarayacak bir otonom Web Scraping mimarisi üzerine inşa edilmiştir. Standart endüstriyel scraping yöntemlerinin aksine bu projede, hedef sunucuları yormayacak ve aynı zamanda yüksek performans sağlayacak şekilde asenkronik (asyncio) bir istek yapısı (cloudscraper tabanlı modüller) kullanılmıştır.

Web kazıma işlemi temel olarak iki ana aşamadan oluşmaktadır. İlk aşamada, belirlenen haber kaynaklarının "asayiş" ve "güncel" kategorilerine (örneğin; /kocaeli-asayis-haberleri) ait ana sayfalar taratılarak asıl haber URL'leri elde edilmektedir. Bu aşamada haber dışı gürültüyü (spor, magazin, ekonomi) filtrelemek amacıyla kural tabanlı bir URL engelleme listesi (blacklist) oluşturulmuş ve yalnızca geçerli formattaki haber bağlantıları toplanmıştır.

İkinci aşamada ise, toplanan URL'lerin içeriklerine erişilmektedir. Sistem bu noktada önemli bir teknik engeli; haber sitelerinin entegre ettiği agresif Cloudflare Turnstile ve Web Application Firewall (WAF) bot korumalarını aşmak zorundadır. Bu problemi çözmek için sistem mimarisine özel bir güvenlik atlatma (bypass) yordamı tasarlanmıştır. SeleniumBase aracı tespitten kaçınan sürümüyle (Undetected ChromeDriver / UC Mode) sanal bir tarayıcı ortamı (headless/headed browser)

başlatmakta, sitelerin CAPTCHA kontrollerini otonom bir şekilde aşarak güvenli istemci çerezlerini (cf_clearance ve User-Agent) bellek ortamında (cache) muhafaza etmektedir. Elde edilen bu yetkilendirilmiş çerezler, yüksek hızlı asenkron istemcilere enjekte edilerek 403 (Forbidden) engelleri tamamen ortadan kaldırılmıştır.

Son olarak, veri setinin güncelliğini korumak maksadıyla HTML5 meta etiketleri (article:published_time veya itemprop='datePublished') analiz edilmiştir. Sisteme dâhil edilecek tüm haberlerin, Python'un dahili tarih/zaman kütüphaneleri (datetime) aracılığıyla değerlendirilerek yalnızca son 3 gün içerisinde yayımlanmış olması koşulu katı bir biçimde uygulanmıştır. Üç günden daha eski olarak tespit edilen içerikler bellek tüketiminin önüne geçmek amacıyla henüz metin işleme aşamasına girmeden sistem ağından ihraç (discard) edilmiştir.

B. Veri Temizleme ve Ön İşleme

Web scraping aracılığıyla dinamik sitelerden toplanan ham HTML (HyperText Markup Language) verisi; reklam panoları, site içi navigasyon menüleri, okuyucu yorumları, gömülü JavaScript kodları ve sayfa stilleri (CSS) gibi haberin asıl bağlamı ile ilgisi olmayan yüksek oranda yapısal gürültü (noise) içermektedir. Doğal Dil İşleme (NLP) aşamasında sınıflandırma algoritmalarının başarısını maksimize etmek ve bellek kullanımını minimize etmek amacıyla, veri seti üzerinde katı bir veri ön işleme (Data Preprocessing) hattı uygulanmıştır.

İşlem adımları BeautifulSoup kütüphanesinin ağaç ayrıştırma (tree parsing) yetenekleri üzerine kurgulanmıştır. İlk adım olarak; script, style, nav, footer, header, aside ve form etiketleri altındaki tüm veri blokları ayrıştırılarak (extract) veri havuzundan tamamen silinmiştir. Bu sayede, reklam metinlerinin veya site içi diğer alakasız bağlantıların hatalı biçimde yapay zekaya veya benzerlik fonksiyonlarına beslenmesinin kesin olarak önüne geçilmiştir.

Gürültü eliminasyonu sonrasında, haberin asıl içeriğini oluşturan paragraf (<p>) etiketleri hedef alınmış, ancak kısa buton çağrıları (call-to-action) veya yazar kısa künyelerinin sızmasını engellemek maksadıyla yalnızca içeriği 20 karakter sınırını aşan düğümler (nodes) geçerli veri (valid text) kabul edilmiştir.

Son safha olan metin normalizasyonu (Text Normalization) aşamasında, haber sitelerinin şablonlarından kaynaklanan fazla boşluklar, görünmez enter ve sekme (tab) karakterleri temizlenmektedir. Saf metne (plaintext) indirgenen string verisi boşluklarına göre bölünmekte (split()) ve satır sonları temizlenerek (strip()) ardışık çoklu boşluk hatalarından arındırılmaktadır. Bu sayede makine öğrenmesi modellerinin anlayabileceği en temiz tekdüze metin formu elde edilerek NLP işleme hattına hazır hale getirilmektedir.

C. Metin Benzerliği ve Tekrar Kontrolü

Özellikle yerel habercilik alanında, aynı coğrafi olay (örneğin trafik kazası veya elektrik kesintisi) birden fazla basın veya yayın kuruluşu tarafından farklı cümle dizilimleriyle veya ufak başlık değişiklikleriyle aynı anda yayımlanmaktadır. Veritabanının şişmesini ve harita üzerindeki olay pinlerinin iç içe geçip kullanıcı deneyimini bozmasını (visual clutter) önlemek amacıyla sisteme yapay zeka destekli bir Doğal Dil İşleme algoritması entegre edilmiştir.

Geleneksel birebir metin veya başlık eşleştirme (exact string matching) stratejileri, içerikte değişen tek bir kelimeden dahi etkilenebildiği için oldukça kırılgandır. Bu projede, her bir makalenin gövde yapısının özellik vektörüne dönüştürülmesi için istatistiksel tabanlı TF-IDF (Term Frequency-Inverse Document Frequency - Terim Frekansı - Ters Belge Frekansı) algoritmasından yararlanılmıştır. Havuzdaki mevcut haberler ve yeni gelen haberlerin tamamı, aynı küresel (global) kelime haznesine (vocabulary) oturtularak TfidfVectorizer ile matematiksel bir matris uzayına taşınmıştır.

Benzerlik ölçümü için, konumları uzaysal boyutta vektörleştirilmiş haber dokümanları arasındaki skaler çarpımı kullanan Kosinüs Benzerliği (Cosine Similarity) formülü uygulanmıştır. Hesaplanan bu metrik, metinlerin uzunluğundan bağımsız olarak içerdikleri bağlamın yönsel benzerliğini matematiksel oranda ortaya koymaktadır.

Her yeni haber kaydı gelmeden hemen önce [0, 1] aralığında sonuç üreten bu matris tetiklenir ve yeni makale, önceden kaydedilmiş veri tabanı külliyatıyla (corpus) iteratif ve enine bir karşılaştırmaya girer. Proje kuralları gereğince, elde edilen Kosinüs Benzerliği metriği max_sim >= 0.90 (Yüzde 90 ve üzeri) baraj puanını aşarsa ilgili içerik mükerrer (duplicate) haber olarak etiketlenmektedir.

Sistemimiz bu noktada benzersiz bir mimari kullanır: Mükerrer haber çöpe atılmaz. Bunun yerine, asıl (original) haberin MongoDB'deki belgesi (document) güncellenerek, ikinci veya üçüncü kaynak bilgilerini dinamik $addToSet mantığı ile tekil haberin "kaynaklar (sources)" dizisi (array) altına birleştirir. Böylece %90 barajı sayesinde kullanıcılara hem haberin tüm yayıncıları gösterilmiş olur hem de harita pürüzsüz tutulur.

D. Haber Türü Sınıflandırma ve Konum Çıkarımı

Proje gereksinimlerinde asgari düzeyde bir "anahtar kelime" tabanlı sınıflandırma sistemi talep edilmesine karşın, sistem mimarimizde doğruluk payını (accuracy) endüstri standartlarına çekmek amacıyla Gelişmiş Doğal Dil İşleme (NLP) ve Zero-Shot Sınıflandırma (Zero-Shot Classification) modelleri uygulanmıştır. Haber içeriklerinin kategorize edilmesi sürecinde, kelime sayma gibi ilkel if-else bloklarının ötesine geçilerek metnin semantik (anlamsal) yapısını algılayabilen derin öğrenme tabanlı MoritzLaurer/mDeBERTa-v3-base-mnli-xnli modeli HuggingFace entegrasyonuyla transformers kütüphanesi üzerinden sisteme gömülmüştür.

Performans darboğazlarını aşmak amacıyla, mDeBERTa modelinin hesaplama yükü CPU üzerinden alınarak NVIDIA CUDA altyapısı ile GPU donanımına delege edilmiştir. Bu mimari donanım hızlandırması sayesinde, binlerce haberin analiz ve inference süresi dakikalardan saniyelere indirilerek sistemin canlı kullanım senaryolarında (real-time processing) gecikmesiz çalışması garanti altına alınmıştır.

Sınıflandırma mekanizması iteratif olarak şu şekilde çalışır: Otonom sistem metni ve başlığı önce Derin Öğrenme

modülüne aktararak Trafik Kazası, Yangın, Hırsızlık, Elektrik Kesintisi ve Kültürel Etkinlik tahmin etiketleri (labels) için hipotez şablonunda olasılık (score) analizi yapar. Şayet model haber dilini belirsiz bulur veya skor eşiği düşük kalırsa, "Geri Çekilme (Fallback)" güvenlik mekanizması devreye girer. Bu mekanizma haberleri kelime ağırlıklarına ve pozitif-negatif puanlama sistemine (örn: 'spor' veya 'siyaset' geçen kelimelerin metni eksi puana düşürmesi) göre tarayarak sonucu kesinleştirir. Yapılan analiz sonucunda hiçbir kategoriye uymayan (örneğin siyasi tartışma veya spor haberi) düzinelerce içerik doğrudan "DISCARD" edilerek veritabanı kirliliği önlenmiştir.

Olayların gerçekleştiği koordinat analizine geçiş için ise öncelikle Konum Çıkarım (Location Extraction) blokları çalıştırılır. Haber, Python'un Unicode string normalize fonksiyonlarıyla büyük/küçük harf bağımsız ve Türkçe karakter uyumlu (ı-i, İ-i problemleri) hale getirilir. Metin içerisinde Kocaeli'nin demografik yapıtaşı olan 12 ana ilçesi (Gebze, İzmit, Karamürsel vb.) için kelime bazlı haritalama (Regex / String Matching) gerçekleştirilir. Bu süreç sonucunda, haberin içeriğinde net ve belirgin bir ilçe adı geçmeyen sığ metinler "Konum Bulunamadı" olarak işaretlenir. Proje kuralları gereğince, konfigürasyonu veya ilçesi okunamayan olaylar veri setinden sistem düzeyinde çıkarılarak (drop), harita üzerinde asılsız veya rastgele noktalarda gösterilmeleri tamamen engellenmiştir.

1) Sınıflandırmada Kullanılan Anahtar Kelimeler:
Proje isterleri kapsamında kullanılan temel anahtar kelimeler ve mDeBERTa Zero-Shot yapay zeka modeline verilen etiketler Tablo I'de listelenmiştir.

Tablo I
KATEGORI VE ANAHTAR KELIME / MODEL ETIKETI EŞLEŞTIRMELERI

Haber Türü (Sınıf)	Anahtar Kelimeler / Model Etiketleri
Trafik Kazası	kaza, trafik, çarpışma, devrildi, yaralandı
Yangın	yangın, itfaiye, alev, kundaklama, duman
Hırsızlık	hırsız, çaldı, gözaltı, soygun, gasp
Elektrik Kesintisi	elektrik, kesinti, sedaş, karanlık, trafo
Kültürel Etkinlikler	etkinlik, konser, festival, fuar, sergi

2) Konum Çıkarım Yöntemi Özeti:
Veri setinden çekilen her haber metni öncelikle normalize edilip, Kocaeli'nin 12 ana ilçesi (İzmit, Gebze, Gölcük vb.) baz alınarak metin tarama (string matching) işlemine tabi tutulur. Metin içinde hiçbir ilçe bilgisi geçmiyorsa, hatalı görselleştirmeyi ve veri kirliliğini önlemek amacıyla haber proje kuralları gereği haritada gösterilmekten men edilir.

3) Geocoding (Koordinat Dönüştürme) ve Veritabanı Entegrasyonu:
Haber metinleri içerisinden doğal dil işleme rutinleri ile bağımsız olarak ayrıştırılan lokasyon (örneğin; "İzmit", "Gebze") verilerinin, Google Maps entegrasyonu sağlanan kullanıcı arayüzünde (Frontend) görselleştirilebilmesi için mutlak konumsal koordinatlara (Enlem / Boylam) çevrilmesi gerekmektedir. Bu amaç doğrultusunda, proje mimarisine Geocoding (Koordinat Dönüştürme) işlemi için OpenCage Geocoding REST API entegre edilmiştir. Sınıflandırılan lokasyonlar, "İlçe, Kocaeli, Türkiye" şablonunda string formatına dönüştürülerek HTTP üzerinden birer coğrafi sorguya yollanmaktadır.

Endüstri standartlarında API tabanlı çalışan bu tür Geocoding servisleri genellikle kotalı (rate-limited) olduğundan, sistem performansını korumak ve aynı konumlar için gereksiz yere tekrar eden dış ağ (external network) çağrılarını engellemek adına araya asenkron bir "Veritabanı Önbelleği (Database Caching)" katmanı örülmüştür.

Sistemin kalıcı veri depolama birimi olarak, proje spesifikasyonlarında (isterlerinde) zorunlu tutulan MongoDB (NoSQL) veritabanı yönetim sistemi tercih edilmiştir. Geleneksel ilişkisel veritabanlarının (RDBMS) aksine NoSQL teknolojisinin getirdiği esnek doküman (document-based) mimarisi veri yapımıza yüksek bir uyum sağlamaktadır. Eğer Geocoding servisinden dönen JSON yanıtında bir hata oluşursa veya API yanıt veremezse, eksik veya hatalı lokasyona sahip haberler veri bütünlüğünü korumak adına veritabanına kaydedilmeden doğrudan atlanmaktadır (discarding).

Başarılı bir şekilde koordinatları alınan güncel haberler ve API üzerinden eşleştirilen son enlem/boylam (lat/lng) değerleri asenkron olarak MongoDB'ye işlenmektedir. Sistemimiz ilişkisel olmayan veri modeli gereksinimini sonuna kadar kullanmaktadır. Gelişmiş Duplicate algoritması sayesinde farklı haber sitelerinden saptanan mükerrer kopyalar silinmez, aksine MongoDB'nin esnek $addToSet operatörü kullanılarak asıl haberin doküman yapısındaki "kaynaklar (sources)" dizisinde birleştirilir. Farklı platformlardan tetiklenen aynı trafik kazası veya yangın olayının NoSQL mimarisinde nasıl tekil bir uzayda birleştirildiğine dair JSON veri örneği aşağıda sunulmuştur:

MongoDB NoSQL Veri Yapısı (Mükerrer Kayıt Birleştirme Örneği):

```
{
  "_id": "651abc9f783bed2a...",
  "category": "Traffic",
  "location": "İzmit",
  "lat": 40.7654,
  "lng": 29.9408,
  "title": "D-100 Karayolunda Zincirleme Kaza",
  "sources": [ "ozgurkocaeli", "bizimyaka" ]
}
```

III. SISTEM MIMARISI VE TASARIM

Sistemin genel işleyişi, yüksek ölçeklenebilirlik, asenkron veri akışı (asynchronous data flow) ve mikroservis (microservice) esnekliğine dayanan üç katmanlı bir modüler yapıdan oluşmaktadır:

1) **Veri Toplama Katmanı (Data Ingestion Layer):** Python Quart asenkron framework'ü üzerinde çalışan, SeleniumBase UC Mode ile WAF ve CAPTCHA engellerini tespitten kaçınarak atlatan otonom web scraping motorudur.

2) **İşleme ve Analiz Katmanı (Processing & Analysis Layer):** Toplanan verilerin süreçlendiği arka uç (backend) merkezidir. BeautifulSoup ile HTML gürültü temizliği, TF-IDF ve Kosinüs Benzerliği (Cosine Similarity) ile haber mükerrerliğini (duplicate) tespit eden mantık çerçevesi ve HuggingFace üzerinden CUDA destekli grafik işlem birimi (GPU) ile donanım hızlandırmalı mDeBERTa NLP sınıflandırma (Zero-Shot) modülü bu katmanda yer almaktadır. Geocoding için OpenCage API çağrısı da sınıflandırmadan hemen sonra bu aşamada tetiklenmektedir.
3) **Sunum Katmanı (Presentation Layer):** ReactJS ve Vite altyapısıyla geliştirilen son kullanıcı (Frontend) önyüzüdür. REST tabanlı JSON API uç noktaları (endpoints) aracılığıyla elde ettiği temiz veriyi asenkron olarak çeker ve interaktif bir Google Maps paneli üzerinde filtreleme senaryolarıyla kullanıcıya servis eder.

IV. Kullanici Arayüzü ve Entegrasyon

Geliştirilen dinamik platformun ön yüzü (Frontend), güncel tek sayfa uygulaması (Single Page Application - SPA) standartlarına uygun olarak ReactJS ile inşa edilmiştir. Google Maps JavaScript API, sisteme çekirdek harita motoru olarak entegre edilmiştir. Bu sayede, yapılandırılmamış yerel haber metinleri yalnızca bir liste görünümünde değil, konumsal (geospatial) olay pinleri (marker) şeklinde harita üzerinde görselleştirilmektedir. Arayüzün öne çıkan entegrasyon özellikleri şunlardır:

- **Dinamik Filtreleme (Dynamic Filtering):** Kullanıcılar, özel bir kontrol paneli üzerinden haberleri Kategori (Yangın, Trafik vb.), spesifik Kocaeli İlçeleri ve Tarih aralığına göre anlık olarak filtreleyebilmektedir. İstemci tarafında (Client-side) gerçekleşen bu filtreleme, sayfa yenilenmesini beklemeden (no-reload) haritadaki pinleri anında günceller.
- **Bilgi Pencereleri (InfoWindows) ve Veri Birleştirme:** Haritada beliren her bir olay işaretçisi (marker) tıklandığında, haberin başlığı, lokasyonu ve bağlantısı gibi detayları içeren asenkron bilgi pencerelerinde (InfoWindow) sunulmaktadır. Sistemin "Duplicate" algoritması aracılığıyla kaynak dizisi (sources array) altına birleştirilen (*merged*) birden fazla platformda yayımlanmış haberler, aynı InfoWindow içerisinde tüm yayıncılarının bağlantılarıyla birlikte çoklu kaynak şeklinde liste halinde gösterilmektedir.

V. Sonuç ve Değerlendirme

Bu çalışmada, Kocaeli ilindeki yoğun ve dağınık çevrimiçi haber akışı; gelişmiş Doğal Dil İşleme (NLP), otonom Veri Madenciliği ve asenkron Web Teknolojileri mimarisi ile merkezi, akıllı bir konumsal bilgi sistemine dönüştürülmüştür.

Elde edilen teknik bulgulara göre: Güçlü bot korumalarına sahip platformların sistemleri (Cloudflare Turnstile WAF), UC Mode entegrasyonuyla başarılı bir şekilde aşılmış ve kesintisiz veri tedariki sağlanmıştır. Sektörel bir zorluk olan metin mükerrerliği; istatistiksel Kosinüs Benzerliği ($\geq$ 0.90) kullanılarak, gereksiz veritabanı yığını oluşturmadan kaynakları birbirine entegre edecek düzeyde (*$addToSet* mekanizmasıyla) çözülmüştür. GPU ivmeli Zero-Shot Text Classification (mDeBERTa) modellemesi, ilkel anahtar kelime sayımına kıyasla NLP tabanlı çok daha yüksek bir kategorizasyon hassasiyeti sunmuştur. Ayrıca OpenCage Geocoding API ile gelen sorgu limitleme sorunu, MongoDB veritabanı önbelleği (database caching) kullanılarak kalıcı şekilde bertaraf edilmiştir.

Geliştirilen bu entegre proje; sadece bir haritalama uygulaması değil, esnek ve modüler bir büyük veri ve MLOps altyapısı sunmaktadır. Bu altyapının ileriki çalışmalarda (future work) diğer illerin yerel basınlarına genişletilmesi veya canlı acil durum ihbar sistemleriyle entegre edilmesi hedeflenebilir.

Kaynaklar

[1] M. Mintz, "SeleniumBase: Python Framework for Web Automation & Cloudflare Bypass," *GitHub Repository*, 2023. [Çevrimiçi]. Erişim: https://github.com/seleniumbase/SeleniumBase.

[2] L. Richardson, "Beautiful Soup Documentation: Parsing HTML/XML," *Crummy*, 2023. [Çevrimiçi]. Erişim: https://www.crummy.com/software/BeautifulSoup/bs4/doc/.

[3] F. Pedregosa *et al.*, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825-2830, 2011. [TF-IDF ve Kosinüs Benzerliği Algoritmaları].

[4] M. Laurer, W. van Atteveldt, A. S. Casas, ve A. Welbers, "Less Annotating, More Classifying: Addressing the Data Scarcity Issue of Political Content Analysis with Deep Learning," *Political Analysis*, vol. 32, no. 1, 2024. [mDeBERTa-v3 Zero-Shot Modeli].

[5] OpenCage GmbH, "OpenCage Geocoding API: Forward and Reverse Geocoding Platform," *OpenCage Data*, 2024. [Çevrimiçi]. Erişim: https://opencagedata.com/api.

[6] P. G. Jones, "Quart: An Asynchronous Python Micro Framework," *Pallets Projects*, 2023. [Çevrimiçi]. Erişim: https://quart.palletsprojects.com/.

[7] MongoDB Inc., "MongoDB: The Developer Data Platform for NoSQL Database Management," *MongoDB Documentation*, 2024. [Çevrimiçi]. Erişim: https://www.mongodb.com/docs/.

[8] Meta Platforms Inc., "React: The Library for Web and Native User Interfaces," *React.dev*, 2024. [Çevrimiçi]. Erişim: https://react.dev/.

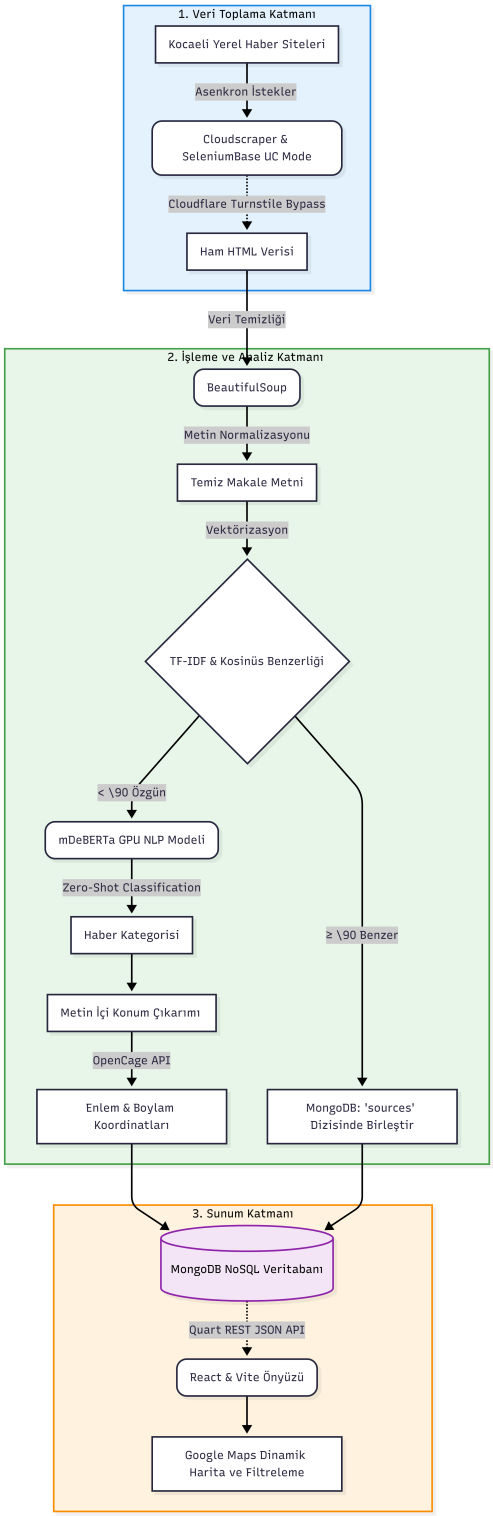

Şekil 1. Kocaeli Live Sistem Mimarisi ve Veri Akış Şeması

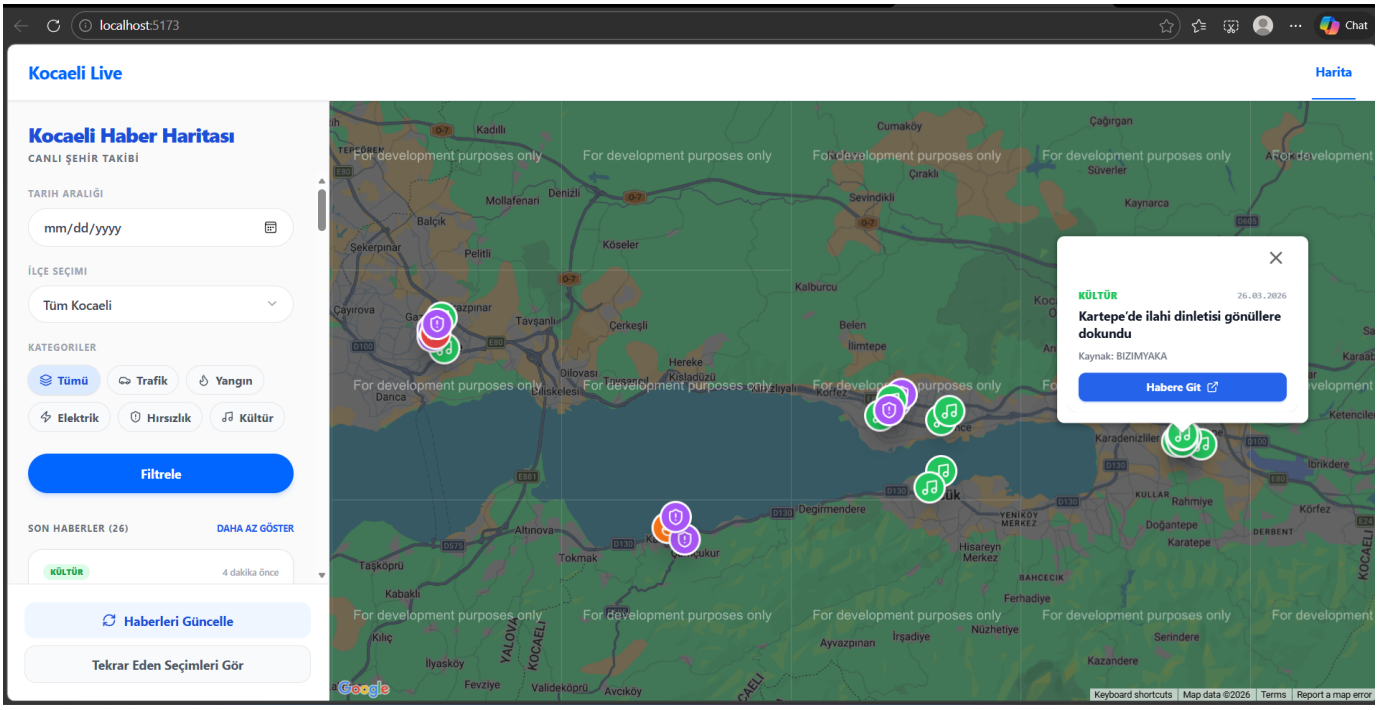

Şekil 2. dinamik filtreleme panelini